Examen domiciliario de R
Universidad Torcuato Di Tella

Bounos, Ian Evangelos - Dolanyi Plaza, Pedro

Aclaraciones Generales

- El trabajo debe subirse a un repositorio de github y enviado a nuestro mail antes del domingo 18 de octubre a las 23:59. Debe contener un informe en pdf, el código y una explicación de READ ME.[1]
- Importante: Deben realizarse el ejercicio de análisis de datos, el ejercicio de análisis econométrico y uno de simulación a elección.
- El trabajo puede realizarse en grupos desde 1 hasta 4 personas, sin excepción.
- Es importante que los códigos estén comentados y sigan buenas prácticas mencionadas en clase.
- Al principio del código pongan `set.seed(algún número)`. Cuando hagan el informe corran todo desde el inicio paso a paso así garantizan que el código es reproducible.
- Resultados que no estén debidamente justificados no obtendrán puntaje. Una correcta justificación consiste en una explicación en el informe y los codes comentados que se utilizaron para resolver el ejercicio.
- Asegúrense de incluir el apellido de todos los integrantes en el nombre del archivo.
- Nos reservamos el derecho a pedir una explicación oral de los resultados en caso de considerarlo necesario.
- El viernes 10 de octubre a las 9 a.m. habrá una clase de consulta por zoom.

Estructura del repositorio

El repositorio debe estar bien organizado en carpetas. En particular:

- Cada ejercicio (Análisis de datos, Análisis econométrico, Simulación) debe estar separado en su propia carpeta, con su propio script principal.
- Las funciones que definan para cada ejercicio deben estar en un script aparte (por ejemplo `funciones.R`), y ser llamadas desde el script principal mediante `source()`. No mezclen definiciones de funciones con el código que las ejecuta.
- Sugerencia de estructura:

[1] Aquí hay un tutorial de github https://www.youtube.com/watch?v=44ziZ12rJwUt=53s pero cualquier cosa nos pueden preguntar sin problemas!

```
nombre-repo/
|-- README.md
|-- informe.pdf
|-- analisis_datos/
|   |-- script_principal.R
|   |-- funciones.R
|   `-- data/
|-- analisis_econometrico/
|   |-- script_principal.R
|   |-- funciones.R
|   `-- data/
`-- simulacion/
    |-- script_principal.R
    |-- funciones.R
    `-- data/
```

Ejercicio de Análisis de datos

La consigna de este ejercicio tiene cierto grado de libertad. Deben elegir un dataset de su gusto – **no hace falta que sea de temática económica**. Hacerse tres preguntas y contestarlas con las herramientas de tidyverse. Pueden usar como referencia el ejercicio de Análisis de datos.

Se sugiere realizar cierta visualización de los datos previa a la respuesta de las preguntas. Por ejemplo, si mi pregunta es cómo difieren las notas de un examen según la edad del alumno, es importante hacer gráficos y verificar, por ejemplo, que no hayan datos inesperados/NAs.

Sugerencias de dónde conseguir un dataset

Si no tienen uno propio en mente, algunas fuentes recomendadas:

- **Kaggle** (https://www.kaggle.com/datasets) – gran variedad de temáticas y niveles de dificultad.
- **UCI Machine Learning Repository** (https://archive.ics.uci.edu/) – datasets clásicos, bien documentados.
- **TidyTuesday** (https://github.com/rfordatascience/tidytuesday) – datasets pensados específicamente para practicar tidyverse.
- **Google Dataset Search** (https://datasetsearch.research.google.com/) – buscador general de datasets.
- **Datos.gob.ar** (https://datos.gob.ar/) – datos abiertos del Estado argentino.
- **EPH – Encuesta Permanente de Hogares** (https://www.indec.gob.ar/indec/web/Institucional-Indec-BasesDeDatos) – microdatos socioeconómicos y laborales de los hogares argentinos, publicados por el INDEC.
- **BA Data – Ciudad de Buenos Aires** (https://data.buenosaires.gob.ar/) – portal de datos abiertos del Gobierno de la Ciudad de Buenos Aires (delitos, transporte, ambiente, economía, etc.).

- **FiveThirtyEight** (https://github.com/fivethirtyeight/data) – datasets de política, deportes, cultura, etc.
- Paquetes de R con datos incorporados, como `palmerpenguins`, `nycflights13` o `gapminder`.

Recomendación: es muy conveniente ir mostrando resultados parciales en clase a los profesores a medida que avanzan, para poder corregir el rumbo a tiempo si algo no está bien encaminado.

Ejercicio: Análisis econométrico con datos de gapminder

En este ejercicio trabajaremos con el dataset gapminder,[2] que contiene información sobre ingresos, esperanza de vida y otros indicadores socioeconómicos de distintos países a lo largo del tiempo. El objetivo es practicar herramientas de regresión, análisis de correlaciones y visualización de datos en R.

Parte 1: Ingreso por persona

1. Grafica la evolución temporal de la variable `income per person` en Argentina. Comenta brevemente la tendencia observada.
2. Para el entrenamiento, separar los últimos 10 años de Argentina para testear posteriormente. Estima regresiones de `income per person` sobre el tiempo t utilizando tres modelos:
   (a) Modelo lineal: income per person $= \beta_1 t + \beta_0 + \varepsilon$
   (b) Modelo polinómico de grado 2: income per person $= \beta_2 t^2 + \beta_1 t + \beta_0 + \varepsilon$
   (c) Modelo polinómico de grado 10: income per person $\sim \beta_0 + \beta_1 t + \beta_2 t^2 + \cdots + \beta_{10} t^{10} + \varepsilon$

   Representa gráficamente los tres ajustes junto con los datos observados y comenta las diferencias. Visualizar y cuantificar los resultados sobre el conjunto de testeo. ¿Qué observa?
3. Selecciona cuatro países sudamericanos distintos de Argentina. Con ellos, arma:
   (a) Una matriz de correlaciones entre los ingresos (`income per person`) de los cinco países.
   (b) Una matriz de correlaciones entre las variaciones porcentuales anuales (crecimiento interanual, $\Delta Y/Y$) de dichos ingresos.

   Discute brevemente las similitudes y diferencias encontradas.

Parte 2: Esperanza de vida y género

Para este ejercicio filtrar únicamente un año en particular a elección.

5. Grafica `life expectancy` frente a `life expectancy female`. ¿Qué relación observas entre ambas variables?
6. Estima una regresión simple de `life expectancy` sobre `life expectancy female`. Analiza el valor del coeficiente estimado. Calcular R^2. ¿Qué observa? ¿Qué implica este resultado?
7. Contrasta la hipótesis nula H_0 : life expectancy female = life expectancy contra la alternativa de que `life expectancy female` es mayor. ¿Cuál es la evidencia empírica al respecto?

[2] Lo tienen disponible en el campus

8. Estima una regresión múltiple de `life expectancy` sobre `life expectancy female` e `income per person`. Interpreta los coeficientes de ambos regresores. Discute qué ocurre con la relación entre esperanza de vida y género al controlar por el nivel de ingresos. Calcular R^2 y comparar con la regresión simple. ¿Vale la pena incluir la variable `income per person`?

9. Excluyendo `life expectancy female` y las variables que por algún motivo considere conveniente excluir, elegir un modelo lineal de máximo tres covariables que explique `life expectancy`. Explicar y justificar cada paso. Aclaración: No es necesario que esas tres covariables sean columnas originales del dataset. Pueden generarse una nueva columna a partir de las existentes.

Ejercicio Simulación 1: Demanda con preferencias Cobb–Douglas

En este ejercicio estudiaremos la demanda de dos bienes de consumo por parte de los hogares bajo preferencias Cobb–Douglas, y cómo reaccionan ante cambios en ingresos y precios mediante simulaciones en R.

Setup. Considera dos bienes, x_1 y x_2, con precios $p_1 > 0$ y $p_2 > 0$. Cada hogar tiene ingreso $Y > 0$ y preferencias representables por una utilidad Cobb–Douglas

$$U(x_1, x_2) = x_1^{\alpha_1} x_2^{\alpha_2},$$

donde $\alpha_1, \alpha_2 \in (0, 1)$ y $\alpha_1 + \alpha_2 = 1$. El hogar elige (x_1, x_2) sujeto a $p_1 x_1 + p_2 x_2 \leq Y$.

1. **Generación de ingresos.** Escribe una función en R llamada `simular_ingreso` que genere el ingreso mensual de un hogar suponiendo que Y sigue una distribución χ^2_k con k grados de libertad. Documenta cómo elegir k y cómo cambia la dispersión de ingresos al variar k.

2. **Demanda óptima Cobb–Douglas.** Define una función `demanda_cd` que, dados $(Y, p_1, p_2, \alpha_1, \alpha_2)$, devuelva el vector de demandas óptimas

   $$x_1^* = \frac{\alpha_1 Y}{p_1}, \qquad x_2^* = \frac{\alpha_2 Y}{p_2},$$

   así como la utilidad indirecta $U^* = (x_1^*)^{\alpha_1} (x_2^*)^{\alpha_2}$.

3. **Simulación base.** Simula al menos 10,000 hogares utilizando las funciones anteriores con parámetros $(k, p_1, p_2, \alpha_1, \alpha_2)$ fijados por vos (explicita los valores). Presenta las distribuciones empíricas de x_1^*, x_2^* y U^* (histogramas o densidades). Reporta también medias y cuartiles.

4. **Probabilidad de bajo consumo en un bien.** Escribe una función `prob_bajo_consumo` que, para un umbral $c > 0$ y un índice de bien $j \in \{1, 2\}$, estime la probabilidad de que $x_j^* < c$ en la población simulada.

5. **Shock de precios.** Supón que ocurre un shock que aumenta el precio del bien 1 en un 20% (i.e., $p_1' = 1.2\, p_1$), manteniendo constante p_2 y los ingresos Y. Repite la simulación y compara las distribuciones de x_1^* antes y después del shock.

6. **Visualización comparada.** Presenta dos histogramas superpuestos (o densidades) de x_1^* pre y post shock. Discute qué sucede con la masa de hogares que consumen muy poco del bien 1 y cómo cambia la utilidad indirecta promedio U^*.

7. **Heterogeneidad en preferencias.** Repite los incisos 3–6 permitiendo heterogeneidad en preferencias: para cada hogar, toma $\alpha_1 \sim \text{Beta}(a, b)$ y define $\alpha_2 = 1 - \alpha_1$. Compara con el caso homogéneo y comenta cómo la dispersión en α_1 afecta la sensibilidad al shock de precios.

Ejercicio Simulación 2: Simulación de ataque en el juego TEG

En clase se explicó cómo funciona el proceso de ataque en el juego TEG.

1. Escribe una función en R llamada `resultado_ataque` que reciba como argumentos la cantidad de dados que utiliza el atacante y la cantidad de dados que utiliza el defensor. La función debe devolver un vector con el resultado de la comparación de los dados, indicando cuántas fichas pierde cada jugador.

2. A continuación, escribe una función en R llamada `simular_batalla` que reciba como argumentos el número de fichas del atacante y del defensor, y que simule una batalla completa. El atacante atacará hasta que conquiste el territorio o se quede con una sola ficha. La función debe devolver el resultado final de la batalla.

3. Usando las funciones anteriores, escribe una función `probabilidad_ataque` que simule 1000 batallas donde el atacante comienza con 5 fichas y el defensor con 5 fichas. La función debe devolver una estimación de la probabilidad de que el atacante conquiste el territorio.

Ejercicio Simulación 3: envido en el Truco

En este ejercicio estudiaremos mediante simulaciones en R el cálculo de tantos de envido y las probabilidades de ganar en distintas situaciones de juego del Truco.

1. Genera una variable `mazo` que contenga todas las cartas del Truco (mazo español de 40 cartas: valores del 1 al 7 y del 10 al 12 en los cuatro palos: espadas, bastos, oros y copas).

2. Define una función `sacar_al_azar(mazo)` que simule la extracción aleatoria de tres cartas y devuelva tanto la mano obtenida como el mazo restante. Graficar un histograma del valor medio.

3. Implementa una función `contar_tantos(mano)` que, dada una mano de tres cartas, calcule los tantos de envido siguiendo las reglas:

   - Si hay al menos dos cartas del mismo palo, se suman sus valores de envido (las cartas del 1 al 7 valen su número, y las del 10, 11 y 12 valen 0) y se agrega un bono de 20.
   - Si no hay dos del mismo palo, el tanto es el mayor valor de envido entre las tres cartas.

4. Escribe una función que, dada tu mano y el mazo restante, calcule la probabilidad exacta de que el oponente gane el envido en un partido de a dos. Considera que en caso de empate gana el jugador que es mano.

5. Simula la siguiente situación: estás jugando al Truco de seis jugadores (tres contra tres). Ya tienes tus tres cartas, y tus compañeros te hicieron seña de que poseen menos de 27 tantos cada uno. Calcula la probabilidad de que tu equipo gane el envido frente al equipo rival, teniendo en cuenta que:

   - El envido lo gana el jugador con el mayor puntaje individual.
   - En caso de empate, gana el equipo del jugador que sea mano.

6. (Opcional) Simula muchas partidas y presenta un histograma del valor del máximo puntaje de envido alcanzado entre los tres jugadores del equipo rival. Analiza qué tan frecuentes son los valores altos y cómo esto influye en la estrategia de tu equipo.